

GRADO EN INGENIERÍA INFORMÁTICA DE GESTIÓN Y SISTEMAS DE INFORMACIÓN

TRABAJO DE FIN DE GRADO

CONVERSIÓN DE ACTAS DEL AYUNTAMIENTO DE BILBAO A KNOWLEDGE GRAPHS (RDF, OWL, SPARQL, SHACL) Y VECTORIAL MEDIANTE LLMS, ENLAZADO CON WIKIDATA Y OFRECIENDO FUNCIONALIDAD RAG. INTERFAZ WEB: VISUAL, CONSULTAS, CONVERSACIONAL

Alumno: Lopez, Sanchez, Peio

Director: Egaña Aranguren, Mikel

Curso: 2026-2027

Fecha: <XXXX, día, mes, año>

Resumen Laburpena Abstract

Este trabajo aborda la conversión de las actas del Pleno del Ayuntamiento de Bilbao (2007–2026), publicadas en formato PDF, en dos sistemas de recuperación de información consultables en lenguaje natural: un RAG vectorial y un sistema GraphRAG.

Las actas se obtienen mediante la descarga automatizada del portal de actas del Ayuntamiento, y de cada una se extraen las proposiciones individuales del Pleno junto con sus metadatos: fecha y sesión plenaria, grupo político o particular proponente, tema, entidades mencionadas, resultado de la votación (agregado por grupo y, cuando el acta lo recoge de forma explícita, nominal por concejal), y página y documento de origen. A partir de estos datos se construye un grafo de conocimiento RDF/OWL que modela proposiciones, grupos políticos, concejales y temas; un modelo de lenguaje clasifica temáticamente cada proposición y extrae las entidades que menciona, incorporando dicha información al grafo.

Sobre este corpus de casi 3.900 proposiciones se implementan dos sistemas de recuperación complementarios: un RAG vectorial, con búsqueda híbrida y reordenación de resultados, y un sistema GraphRAG, que traduce la pregunta a una consulta SPARQL, la ejecuta sobre el grafo mediante razonamiento automático para responder preguntas de agregación, y genera la respuesta a partir de los datos obtenidos.

Ambos sistemas citan la página exacta del documento de origen de cada dato mostrado, y se exponen mediante una interfaz web conversacional construida con Chainlit. El trabajo incluye una evaluación comparativa sistemática de ambas arquitecturas sobre un conjunto de preguntas de referencia con respuesta verificada a mano contra las actas originales.

Palabras Clave: GraphRAG, RAG, LLM, grafo de conocimiento, SPARQL.

[PENDIENTE]

Gako-hitzak: GraphRAG, RAG, LLM, ezagutza-grafoa, SPARQL.

[PENDIENTE]

Keywords: GraphRAG, RAG, LLM, knowledge graph, SPARQL.

Índice

Resumen Laburpena Abstract	1
Lista de figuras	5
Lista de tablas	6
Lista de acrónimos	7
1. Introducción	8
1.1. Descripción del problema	8
1.2. Estructura de la memoria	8
2. Contexto	10
2.1. Inteligencia Artificial Generativa	10
2.2. Modelos de Lenguaje de Gran Tamaño	10
2.3. Retrieval Augmented Generation (RAG)	10
2.4. Grafos de Conocimiento	11
2.5. GraphRAG	11
3. Objetivos y alcance	12
3.1. Objetivos del TFG	12
3.2. Alcance del sistema desarrollado	12
4. Beneficios que aporta el trabajo y relación con los Objetivos de Desarrollo Sostenible	13
4.1. Beneficios del sistema desarrollado	13
4.2. Relación con los Objetivos de Desarrollo Sostenible	13
5. Descripción de requerimientos y análisis del estado del arte	14

5.1. Corpus documental	14
5.2. Requisitos del sistema	14
5.3. Estado del arte de las tecnologías utilizadas	14
6. Análisis de alternativas	15
6.1. Modelos de lenguaje: local (Ollama) frente a API en la nube (Groq / Gemini)	15
6.2. Almacenamiento del grafo: rdflib/OWL-RL frente a una base de grafos dedicada (p.ej. GraphDB, Neo4j)	15
6.3. Almacén vectorial y recuperación: ChromaDB e híbrida (semántica + literal + temática) frente a solo semántica	15
7. Análisis de riesgos	16
7.1. Medidas de prevención y contingencia	16
8. Descripción de la solución propuesta	17
8.1. Arquitectura general del sistema	17
8.2. Pipeline de procesamiento de datos	17
8.3. Construcción del grafo de conocimiento	17
8.4. Sistema de recuperación de información	17
8.5. Generación de respuestas	18
8.6. Interfaz web del sistema	18
8.7. Flujo completo del sistema	18
8.8. Implementación técnica	18
9. Planificación del proyecto	19
9.1. Diagrama EDT	19
9.2. Descripción de tareas	19
9.3. Diagrama de Gantt	19
9.4. Metodología de desarrollo	19
10. Análisis de resultados	20
10.1. Objetivo de la evaluación	20
10.2. Metodología	20
10.3. Métricas utilizadas	20
10.4. Experimentos realizados	20
10.5. Resultados obtenidos	20

10.6. Limitaciones	20
11.Descripción del presupuesto	21
11.1. Costes en software y hardware	21
11.2. Costes por mano de obra	21
12.Conclusiones	22
12.1. Conclusiones sobre el sistema	22
12.2. Cumplimiento de objetivos	22
12.3. Conclusiones sobre las pruebas realizadas	22
12.4. Mejoras futuras	22
Bibliografía	23

Lista de figuras

Lista de tablas

Lista de acrónimos

LLM Large Language Model

RAG Retrieval Augmented Generation

GraphRAG Graph Retrieval Augmented Generation

RDF Resource Description Framework

OWL Web Ontology Language

SPARQL SPARQL Protocol and RDF Query Language

SKOS Simple Knowledge Organization System

SHACL Shapes Constraint Language

LOD Linked Open Data

API Application Programming Interface

PDF Portable Document Format

OCR Optical Character Recognition

TFG Trabajo Fin de Grado

1. Introducción

1.1. Descripción del problema

El portal de actas del Ayuntamiento de Bilbao publica, para cada sesión del Pleno desde 2007 hasta la actualidad, varios documentos PDF distintos: el orden del día, extractos, el resumen de la sesión y el acta completa. De estos, el acta es el único que recoge de forma íntegra las proposiciones, el debate y el resultado de cada votación, por lo que es el documento que utiliza este trabajo; cada acta puede superar el centenar de páginas, y el corpus completo reúne cerca de veinte años de actas y más de 3.900 proposiciones distintas.

Dentro de cada acta, además, el contenido relevante –las proposiciones y sus votaciones– se mezcla con una cantidad considerable de contenido puramente procedimental: listas de asistentes, fórmulas de quórum, aprobación del acta anterior, cuestiones de orden o informes que solo se dan por conocidos sin votación. Identificar qué parte de cada acta es efectivamente una proposición –y separarla del resto– es en sí mismo parte del problema a resolver.

A esto se suma un problema práctico adicional: encontrar información concreta –qué votó un grupo político sobre un tema, cuántas proposiciones sobre vivienda se presentaron en un año determinado, cómo ha evolucionado un asunto a lo largo de los mandatos– exige leer manualmente decenas de documentos extensos, o como mínimo saber de antemano en qué fecha y página buscar. No existe ninguna vía para hacer preguntas en lenguaje natural sobre este archivo y obtener una respuesta verificable, con cifras y citas a la fuente original.

1.1.1. Acceso a la información municipal

El objetivo de este TFG es cerrar esa brecha: construir un sistema que permita consultar en castellano, mediante preguntas formuladas de forma natural, el contenido íntegro de las actas del Pleno, y que responda con datos verificables –enlazados a la página exacta del PDF de origen– en lugar de con texto generado sin respaldo documental.

1.2. Estructura de la memoria

Esta memoria se organiza como sigue. El Capítulo 2 introduce los conceptos técnicos en los que se apoya el sistema (modelos de lenguaje, RAG, grafos de conocimiento y GraphRAG). El Capítulo 3 concreta los objetivos del trabajo y su alcance real. El Capítulo 4 discute los beneficios del sistema y su relación con los Objetivos de Desarrollo

Sostenible. Los capítulos siguientes describen el estado del arte, el análisis de alternativas tecnológicas, los riesgos del proyecto y, con más detalle, la solución desarrollada: los dos sistemas de recuperación de información contruidos –uno basado en búsqueda vectorial y otro en un grafo de conocimiento RDF/OWL consultado por SPARQL– y la interfaz web conversacional que los expone al usuario. La memoria cierra con la planificación seguida, el presupuesto, las conclusiones y los anexos.

2. Contexto

A continuación se presentan los conceptos técnicos en los que se apoya este trabajo: los modelos de lenguaje y la generación aumentada por recuperación (RAG), los grafos de conocimiento, y GraphRAG como la combinación de ambos. Estos conceptos son la base sobre la que se construyen los dos sistemas de recuperación de información comparados en este TFG.

2.1. Inteligencia Artificial Generativa

La Inteligencia Artificial (IA) Generativa agrupa a los modelos capaces de producir contenido nuevo –texto, código, imágenes– a partir de un patrón aprendido de grandes cantidades de datos, en lugar de limitarse a clasificar o predecir sobre datos ya existentes. Los modelos de lenguaje son el caso particular relevante para este trabajo: reciben texto como entrada y generan texto como salida, condicionados por una instrucción (*prompt*).

2.2. Modelos de Lenguaje de Gran Tamaño

Los Modelos de Lenguaje de Gran Tamaño (LLM, *Large Language Models*) son redes neuronales entrenadas sobre corpus masivos de texto que, dada una secuencia de entrada, predicen la continuación más probable. Esta capacidad, combinada con un ajuste posterior para seguir instrucciones, permite emplearlos para tareas tan diversas como resumir, traducir, generar código o –el uso que se les da en este TFG– extraer información estructurada de texto libre y redactar respuestas a partir de datos ya recuperados.

Un LLM no tiene, por sí mismo, acceso a información posterior a su entrenamiento ni a documentos privados como las actas de un ayuntamiento concreto. Tampoco garantiza que lo que genera sea correcto: puede producir afirmaciones plausibles pero falsas, fenómeno conocido como *alucinación*. Ambas limitaciones son las que motivan la siguiente técnica.

2.3. Retrieval Augmented Generation (RAG)

Retrieval Augmented Generation (RAG) es una arquitectura que combina un sistema de recuperación de información con un LLM: antes de generar la respuesta, se buscan en una base documental los fragmentos más relevantes para la pregunta y se proporcionan al modelo como contexto. El LLM genera entonces la respuesta apoyándose únicamente en esos fragmentos, no en su conocimiento interno.

Esto tiene dos ventajas directas para este proyecto: permite responder sobre un corpus privado y actualizable (las actas del Pleno) sin reentrenar ningún modelo, y permite citar la fuente exacta de cada afirmación, ya que se conoce qué fragmentos –y por tanto qué documento y página– sustentan la respuesta.

La recuperación de los fragmentos relevantes suele apoyarse en *embeddings*: representaciones vectoriales del texto en las que fragmentos semánticamente similares quedan cerca en el espacio vectorial, lo que permite buscar por significado y no solo por coincidencia literal de palabras.

2.4. Grafos de Conocimiento

Un grafo de conocimiento representa la información como una red de entidades (nodos) y relaciones entre ellas (aristas), en lugar de como texto libre. El estándar utilizado en este trabajo es RDF (*Resource Description Framework*), que modela cada hecho como una tripleta *sujeto-predicado-objeto* (por ejemplo, **proposición X --presentadaPor-->Grupo PP**). Sobre RDF se puede definir una ontología con OWL (*Web Ontology Language*) –las clases y relaciones válidas del dominio– y consultar el grafo con el lenguaje SPARQL.

Una ventaja de este modelo frente al texto libre es el razonamiento automático: un motor de inferencia (*reasoner*) puede derivar hechos nuevos que no están escritos explícitamente pero se siguen de la ontología –por ejemplo, que una proposición sobre “desahucios” trata también, por herencia temática, de “vivienda- sin que haga falta repetir esa relación en cada dato.

2.5. GraphRAG

GraphRAG es la variante de RAG en la que la fuente de recuperación no es un almacén de fragmentos de texto sino un grafo de conocimiento consultado mediante un lenguaje de consulta estructurado (SPARQL en este trabajo). En lugar de recuperar pasajes de texto parecidos a la pregunta, un LLM traduce la pregunta en lenguaje natural a una consulta formal, el motor de grafos la ejecuta y devuelve filas de datos exactos, que un segundo LLM convierte en una respuesta narrada.

Esto resulta especialmente adecuado para preguntas de agregación y razonamiento multi-salto –“¿qué grupo ha presentado más proposiciones sobre vivienda?”, “¿cuántas se han aprobado por año?”– que un sistema de recuperación de texto libre no puede responder con precisión, porque exigen contar y cruzar datos de todo el corpus, no solo encontrar un pasaje parecido a la pregunta. Es, junto con el RAG vectorial tradicional, uno de los dos sistemas comparados en este TFG.

3. Objetivos y alcance

A continuación se presentan los objetivos definidos para este TFG, así como el alcance del sistema finalmente implementado.

3.1. Objetivos del TFG

Se presenta el objetivo general del trabajo y los objetivos específicos que se derivan de él.

3.2. Alcance del sistema desarrollado

Se describe qué incluye y qué queda fuera del sistema final, y por qué – p.ej. el enlazado con Wikidata, que se valoró y se descartó para esta entrega.

4. Beneficios que aporta el trabajo y relación con los Objetivos de Desarrollo Sostenible

A continuación se explica a quién beneficia el sistema desarrollado y cómo se relaciona con los Objetivos de Desarrollo Sostenible de la Agenda 2030.

4.1. Beneficios del sistema desarrollado

Se identifican los distintos perfiles de usuario a los que beneficia el sistema y de qué forma.

4.2. Relación con los Objetivos de Desarrollo Sostenible

Se relacionan los ODS pertinentes con el trabajo desarrollado.

5. Descripción de requerimientos y análisis del estado del arte

A continuación se describe el corpus documental de partida, los requisitos que debía cumplir el sistema y el estado del arte de las tecnologías empleadas.

5.1. Corpus documental

Se describen los documentos que publica el portal de actas del Ayuntamiento, cuál de ellos usa este trabajo y por qué, y las limitaciones que tiene como fuente (PDF escaneado/OCR, falta de estructura, etc.).

5.2. Requisitos del sistema

Se enumeran los requisitos funcionales y no funcionales del sistema final.

5.3. Estado del arte de las tecnologías utilizadas

Se revisan trabajos y sistemas similares existentes – otros RAG/GraphRAG sobre actas o documentos administrativos – y se compara con el TFG de Oiher Rodríguez Luengo como referencia más cercana.

6. Análisis de alternativas

A continuación se comparan las principales decisiones tecnológicas evaluadas antes de fijar la arquitectura final del sistema.

6.1. Modelos de lenguaje: local (Ollama) frente a API en la nube (Groq / Gemini)

6.1.1. Puntos positivos

6.1.2. Puntos negativos

6.1.3. Conclusión

6.2. Almacenamiento del grafo: rdflib/OWL-RL frente a una base de grafos dedicada (p.ej. GraphDB, Neo4j)

6.2.1. Puntos positivos

6.2.2. Puntos negativos

6.2.3. Conclusión

6.3. Almacén vectorial y recuperación: ChromaDB e híbrida (semántica + literal + temática) frente a solo semántica

6.3.1. Puntos positivos

6.3.2. Puntos negativos

6.3.3. Conclusión

7. Análisis de riesgos

A continuación se identifican los principales riesgos del proyecto y las medidas adoptadas para prevenirlos o mitigarlos.

7.1. Medidas de prevención y contingencia

Se detallan los riesgos identificados (p.ej. dependencia de APIs externas, calidad del OCR de las actas antiguas, coste o límite de peticiones a los LLM) y cómo se mitigó cada uno.

8. Descripción de la solución propuesta

A continuación se describe en detalle el sistema desarrollado: su arquitectura, el pipeline de datos, el grafo de conocimiento, los dos motores de recuperación y la interfaz que los expone al usuario.

8.1. Arquitectura general del sistema

Se presenta la visión general de los componentes del sistema y cómo se conectan entre sí.

8.2. Pipeline de procesamiento de datos

Se describe el proceso completo desde el scraping de las actas hasta el enriquecimiento de las proposiciones con un LLM mediante un esquema JSON cerrado (ver Capítulo 2).

8.3. Construcción del grafo de conocimiento

Se describe la ontología OWL, el paso de JSON a triples RDF, el razonamiento automático (*roll-up* temático) y la validación SHACL del grafo.

8.4. Sistema de recuperación de información

Se describen los dos motores de recuperación implementados sobre el mismo corpus.

8.4.1. RAG vectorial

8.4.2. GraphRAG

8.5. Generación de respuestas

Se explica cómo se narra la respuesta a partir de los datos recuperados, y cómo se citan las fuentes (página y documento exactos) en ambos sistemas.

8.6. Interfaz web del sistema

Se describen los componentes de la interfaz Chainlit y el flujo de uso.

8.7. Flujo completo del sistema

8.8. Implementación técnica

9. Planificación del proyecto

A continuación se describe la planificación temporal seguida durante el desarrollo del trabajo.

9.1. Diagrama EDT

9.2. Descripción de tareas

9.2.1. Gestión del proyecto

9.2.2. Investigación y estudio previo

9.2.3. Desarrollo del sistema

9.2.4. Evaluación del sistema

9.2.5. Documentación

9.3. Diagrama de Gantt

9.4. Metodología de desarrollo

10. Análisis de resultados

A continuación se presenta la evaluación comparativa de los dos sistemas desarrollados: RAG vectorial y GraphRAG.

10.1. Objetivo de la evaluación

Se explica qué se quiere medir al comparar ambos sistemas.

10.2. Metodología

Se describe la batería de preguntas de referencia y su verificación manual contra las actas originales en PDF.

10.3. Métricas utilizadas

10.4. Experimentos realizados

10.5. Resultados obtenidos

10.6. Limitaciones

11. Descripción del presupuesto

A continuación se detalla el presupuesto estimado del proyecto.

11.1. Costes en software y hardware

11.2. Costes por mano de obra

12. Conclusiones

A continuación se recogen las conclusiones del trabajo, el grado de cumplimiento de los objetivos planteados y las mejoras futuras identificadas.

12.1. Conclusiones sobre el sistema

12.2. Cumplimiento de objetivos

12.3. Conclusiones sobre las pruebas realizadas

12.4. Mejoras futuras

Se recogen el enlazado con Wikidata sobre entidades no personales, la desambiguación por género de concejales homónimos, y otras mejoras apuntadas durante el desarrollo.

Bibliografía

[1] Autores. *Título*. Editorial, Año.

[2] Autores. *Título*. Editorial, Año. <https://www.example.com>