

GRADO EN INGENIERÍA INFORMÁTICA DE GESTIÓN Y SISTEMAS DE INFORMACIÓN

TRABAJO DE FIN DE GRADO

**CONVERSIÓN DE ACTAS DEL AYUNTAMIENTO DE
BILBAO A KNOWLEDGE GRAPHS (RDF, OWL,
SPARQL, SHACL) Y VECTORIAL MEDIANTE LLMS,
ENLAZADO CON WIKIDATA Y OFRECIENDO
FUNCIONALIDAD RAG. INTERFAZ WEB: VISUAL,
CONSULTAS, CONVERSACIONAL**



Alumno: Lopez, Sanchez, Peio

Director: Egaña Aranguren, Mikel

Curso: 2026-2027

Fecha: <XXXX, día, mes, año>

Resumen Laburpena Abstract

Resumen:

Este trabajo aborda la transformación de las actas del Pleno del Ayuntamiento de Bilbao (2007–2026), publicadas en formato PDF, en dos sistemas complementarios de recuperación de información consultables en lenguaje natural: un RAG vectorial y un sistema GraphRAG. A partir de la descarga automatizada del portal municipal, se extraen de forma estructurada las proposiciones individuales junto con sus metadatos esenciales: fecha de la sesión, proponente, tema, entidades, página exacta y el resultado de la votación –tanto agregado por grupo como nominal por concejal cuando consta en el acta–. Esta información nutre un grafo de conocimiento RDF/OWL que modela la actividad plenaria, combinando extracción determinista para garantizar la fidelidad de los votos con modelos de lenguaje para la clasificación temática y el reconocimiento de entidades.

Sobre este corpus de 3.422 proposiciones se implementan dos arquitecturas de consulta: un RAG vectorial con búsqueda híbrida multicanal y reordenación semántica (reranking), y un sistema GraphRAG que traduce el lenguaje natural a consultas SPARQL para resolver preguntas de agregación y conteo mediante razonamiento automático. Ambos sistemas garantizan la trazabilidad citando la página exacta del documento original y se integran en una interfaz conversacional construida con Chainlit. El trabajo concluye con una evaluación comparativa sistemática sobre un conjunto de preguntas de referencia contrastadas exhaustivamente contra los documentos oficiales.

Palabras Clave: GraphRAG, RAG vectorial, grafo de conocimiento, SPARQL, LLM, datos abiertos municipales.

Laburpena:

Lan honek Bilboko Udalaren Osoko Bilkuraren aktak (2007–2026), PDF formatuan argitaratuak, hizkuntza naturalean kontsultatu daitezkeen informazio-berreskurapeneko bi sistema osagarritan –RAG bektorial bat eta GraphRAG sistema bat– eraldatzeari ekiten dio. Udalaren atarian modu automatizatuan deskargatutako aktetatik, egiturazko moduan ateratzen dira proposamen individualak, beren funtsezko metadatuekin batera: bilkuraren data, proposatzailea, gaia, entitateak, orrialde zehatza eta bozketaren emaitza –taldeka metatuta zein, aktan hala jasotzen denean, zinegotziz zinegotzi–. Informazio horrek RDF/OWL ezagutza-grafo bat elikatzen du, osoko bilkuraren jardura modelatzen duena, bozen zehaztasuna bermatzeko atzemate determinista eta gai-sailkapenerako eta entitateen ezagutzarako hizkuntza-ereduak konbinatuz.

3.422 proposamenez osatutako corpus horren gainean, bi kontsulta-arkitektura ezartzen dira: bilaketa hibrido anizkanaleko eta birsailkapen semantikoko (reranking) RAG bektorial bat, eta hizkuntza naturala SPARQL kontsultetara itzultzen duen GraphRAG sistema bat, arazoiketa automatikoaren bidez metaketa- eta zenbaketa-galderak ebazteko. Bi sistemek

jatorrizko dokumentuaren orrialde zehatza aipatuz bermatzen dute trazabilitatea, eta Chainlit-ekin eraikitako elkarriketa-interfaze batean integratzen dira. Lana jatorrizko dokumentuen aurka zorrotz egiaztatutako erreferentzia-galdera multzo baten gaineko ebaluazio konparatibo sistematiko batekin amaitzen da.

Gako-hitzak: GraphRAG, RAG bektoriala, ezagutza-grafoa, SPARQL, LLM, udal datu irekiak.

Abstract:

This work addresses the transformation of the minutes of the Plenary Session of the Bilbao City Council (2007–2026), published in PDF format, into two complementary natural-language information retrieval systems: a vector RAG and a GraphRAG system. From documents downloaded automatically from the municipal portal, individual proposals are extracted in structured form together with their essential metadata: session date, proposer, topic, entities, exact page, and the outcome of the vote –both aggregated by political group and, when explicitly recorded in the minutes, nominal by councillor–. This information feeds an RDF/OWL knowledge graph that models plenary activity, combining deterministic extraction to guarantee the fidelity of the votes with language models for topic classification and entity recognition.

Two query architectures are implemented over this corpus of 3,422 proposals: a vector RAG with multi-channel hybrid search and semantic reranking, and a GraphRAG system that translates natural language into SPARQL queries to resolve aggregation and counting questions through automated reasoning. Both systems guarantee traceability by citing the exact page of the original document and are exposed through a conversational web interface built with Chainlit. The work concludes with a systematic comparative evaluation over a set of reference questions verified exhaustively against the original documents.

Keywords: GraphRAG, vector RAG, knowledge graph, SPARQL, LLM, open municipal data.

Índice

Resumen Laburpena Abstract	1
Lista de figuras	6
Lista de tablas	7
Lista de acrónimos	9
1. Introducción	10
1.1. Motivación	10
1.2. Objetivos y alcance	11
1.3. Conexión con los Objetivos de Desarrollo Sostenible	12
1.4. Estructura de la memoria	13
2. Contexto	14
2.1. Transparencia y digitalización de la administración pública	14
2.2. El auge de los LLMs	14
2.3. RAG	15
2.4. Grafos de Conocimiento	16
2.5. GraphRAG	16
2.6. El Pleno del Ayuntamiento de Bilbao	16
3. Descripción de requerimientos y análisis del estado del arte	18
3.1. Requisitos del sistema	18
3.2. Estado del arte de las tecnologías utilizadas	19
4. Planificación del proyecto	21
4.1. Diagrama EDT	21

4.2. Descripción de tareas	21
4.3. Gestión del tiempo	26
4.4. Metodología de desarrollo	27
4.5. Evaluación económica	27
4.6. Análisis de riesgos	28
5. Análisis de alternativas	32
5.1. Modelos de lenguaje: local (Ollama) frente a API en la nube (Groq / Gemini)	32
5.2. Almacenamiento del grafo: rdflib/OWL-RL frente a una base de grafos dedicada (p.ej. GraphDB, Neo4j)	33
5.3. Almacén vectorial y recuperación: ChromaDB e híbrida (semántica + literal + temática) frente a solo semántica	34
6. Descripción de la solución propuesta	35
6.1. Arquitectura general del sistema	35
6.2. Construcción del grafo de conocimiento	35
6.3. Sistema de recuperación de información	35
6.4. Generación de respuestas	35
6.5. Interfaz web del sistema	35
6.6. Flujo completo del sistema	35
6.7. Configuración y decisiones de implementación	35
7. Corpus y preprocesado de datos	36
7.1. El corpus de actas del Pleno	36
7.2. Pipeline de preprocesado	36
8. Análisis de resultados	37
8.1. Objetivo de la evaluación	37
8.2. Metodología	37
8.3. Análisis sobre la recuperación	37
8.4. Análisis sobre la generación	37
8.5. Comparativa GraphRAG frente a RAG vectorial	37
8.6. Configuración final y valoración global	37
8.7. Limitaciones	37
9. Conclusiones y trabajo futuro	38

9.1. Conclusiones del trabajo	38
9.2. Cumplimiento de objetivos	38
9.3. Conclusiones sobre las pruebas realizadas	38
9.4. Contribuciones científico-técnicas	38
9.5. Trabajo futuro	38
Bibliografía	39

Lista de figuras

1.	Icono del Objetivo 16: Paz, justicia e instituciones sólidas	13
2.	Icono del Objetivo 11: Ciudades y comunidades sostenibles	13
3.	Fachada del Ayuntamiento de Bilbao	17
4.	Diagrama EDT del proyecto	21
5.	Diagrama de Gantt del proyecto (semanas desde el 22 de enero de 2026) . .	26

Lista de tablas

1.	Requisitos funcionales del sistema	18
2.	Requisitos no funcionales del sistema	19
3.	Paquete de trabajo: 1. Gestión y planificación	22
4.	Paquete de trabajo: 1.1. Reuniones con el director	22
5.	Paquete de trabajo: 1.2. Gestión del tiempo	22
6.	Paquete de trabajo: 2. Investigación y estudio previo	22
7.	Paquete de trabajo: 2.1. Estudio del estado del arte	22
8.	Paquete de trabajo: 2.2. Análisis de alternativas tecnológicas	23
9.	Paquete de trabajo: 3. Desarrollo del sistema	23
10.	Paquete de trabajo: 3.1. Extracción y preprocesado del corpus	23
11.	Paquete de trabajo: 3.2. RAG vectorial	23
12.	Paquete de trabajo: 3.3. GraphRAG	24
13.	Paquete de trabajo: 3.4. Interfaz web	24
14.	Paquete de trabajo: 4. Evaluación del sistema	24
15.	Paquete de trabajo: 4.1. Diseño de la batería de preguntas de referencia	24
16.	Paquete de trabajo: 4.2. Evaluaciones y comparativa	25
17.	Paquete de trabajo: 4.3. Validación contra PDF real y regresión	25
18.	Paquete de trabajo: 5. Documentación	25
19.	Paquete de trabajo: 5.1. Redacción de la memoria	26
20.	Paquete de trabajo: 5.2. Documentación técnica	26
21.	Coste de mano de obra	27
22.	Coste de hardware (amortizado)	28
23.	Coste de software	28
24.	Costes indirectos (electricidad)	28
25.	Coste total del proyecto	29

26.	Riesgo: 1. Dependencia de APIs externas	29
27.	Riesgo: 2. Errores silenciosos en la generación de SPARQL	29
28.	Riesgo: 3. Calidad variable del OCR en actas antiguas	30
29.	Riesgo: 4. Plazo de entrega ajustado con un único desarrollador	30
30.	Riesgo: 5. Nombres y grupos ambiguos o mal atribuidos en las actas	31
31.	Categorías de preguntas de la batería de referencia (ejemplo)	37

Lista de acrónimos

LLM Large Language Model

RAG Retrieval Augmented Generation

GraphRAG Graph Retrieval Augmented Generation

RDF Resource Description Framework

OWL Web Ontology Language

SPARQL SPARQL Protocol and RDF Query Language

SKOS Simple Knowledge Organization System

SHACL Shapes Constraint Language

LOD Linked Open Data

API Application Programming Interface

PDF Portable Document Format

OCR Optical Character Recognition

TFG Trabajo Fin de Grado

1. Introducción

El portal de actas del Ayuntamiento de Bilbao publica, para cada sesión del Pleno desde 2007 hasta la actualidad, varios documentos PDF distintos: el orden del día, extractos, el resumen de la sesión y el acta completa. De estos, el acta es el único que recoge de forma íntegra las proposiciones, el debate y el resultado de cada votación, por lo que es el documento que utiliza este trabajo; cada acta puede superar el centenar de páginas, y el corpus completo reúne cerca de veinte años de actas y 3.422 proposiciones distintas.

Este capítulo presenta la motivación que ha llevado al desarrollo del proyecto, los objetivos planteados, su relación con los Objetivos de Desarrollo Sostenible y la estructura del resto de la memoria.

1.1. Motivación

Dentro de cada acta, el contenido relevante –las proposiciones y sus votaciones– se mezcla con una cantidad considerable de contenido puramente procedimental: listas de asistentes, fórmulas de quórum, aprobación del acta anterior, cuestiones de orden o informes que solo se dan por conocidos sin votación. Identificar qué parte de cada acta es efectivamente una proposición –y separarla del resto– es en sí mismo parte del problema a resolver.

A esto se suma un problema práctico adicional: encontrar información concreta –qué votó un grupo político sobre un tema, cuántas proposiciones sobre vivienda se presentaron en un año determinado, cómo ha evolucionado un asunto a lo largo de los mandatos– exige leer manualmente decenas de documentos extensos, o como mínimo saber de antemano en qué fecha y página buscar. No existe ninguna vía para hacer preguntas en lenguaje natural sobre este archivo y obtener una respuesta verificable, con cifras y citas a la fuente original.

1.1.1. A quién beneficia el sistema

El sistema desarrollado tiene utilidad directa para varios perfiles distintos de usuario, cada uno con una forma de preguntar y un tipo de respuesta que le interesa más:

Ciudadanía Puede preguntar en lenguaje natural por el estado o el resultado de una propuesta concreta –p. ej. “¿qué se votó sobre el polideportivo de mi barrio?”– sin necesidad de conocer de antemano en qué acta ni en qué página buscar, y obtener la cita exacta al documento original como respaldo.

Periodistas Se benefician sobre todo de las preguntas de agregación y comparación entre

grupos políticos –p. ej. cuántas propuestas sobre vivienda ha presentado cada partido en un mandato, o cómo ha votado cada grupo un asunto concreto–, el tipo de consulta en el que el sistema GraphRAG aporta más valor frente a una búsqueda de texto convencional (Capítulo 2).

Personal técnico municipal Puede recuperar rápidamente el precedente de un asunto ya tratado en plenos anteriores –qué se acordó, qué grupo lo propuso, si se aprobó con enmienda– sin depender de la memoria de quien estuvo presente en aquella sesión ni de una búsqueda manual en el archivo.

Investigadores Disponen de un corpus estructurado y consultable de forma sistemática –por tema, por grupo, por periodo temporal– que permite estudiar la actividad plenaria a lo largo de casi veinte años sin procesar manualmente cada acta en PDF.

1.2. Objetivos y alcance

El objetivo general de este TFG es cerrar la brecha descrita en la motivación: construir un sistema que permita consultar en castellano, mediante preguntas formuladas de forma natural, el contenido íntegro de las actas del Pleno, y que responda con datos verificables –enlazados a la página exacta del PDF de origen– en lugar de con texto generado sin respaldo documental.

1.2.1. Objetivos específicos

Del objetivo general se derivan los siguientes objetivos específicos:

1. Extraer de forma automatizada las proposiciones individuales de cada acta – junto con su fecha, grupo o particular proponente, tema, entidades mencionadas y resultado de la votación– a partir del corpus de PDF publicado por el Ayuntamiento (Capítulo 7).
2. Construir un grafo de conocimiento RDF/OWL que modele las proposiciones, los grupos políticos, los concejales y los temas, y que permita razonamiento automático sobre relaciones temáticas jerárquicas (Capítulo 6).
3. Implementar un sistema de recuperación de información basado en búsqueda vectorial híbrida (semántica, literal y temática) sobre el mismo corpus.
4. Implementar un segundo sistema de recuperación, GraphRAG, que traduzca la pregunta del usuario a una consulta SPARQL y la ejecute sobre el grafo de conocimiento, para responder preguntas de agregación y razonamiento multi-salto que el sistema vectorial no puede resolver con precisión.
5. Exponer ambos sistemas mediante una interfaz web conversacional que cite, para cada dato mostrado, el documento y la página exacta del PDF de origen.
6. Evaluar de forma comparativa ambos sistemas sobre un conjunto de preguntas de referencia con respuesta verificada a mano contra las actas originales, para caracterizar en qué tipo de preguntas destaca cada arquitectura (Capítulo 8).

1.2.2. Alcance del sistema desarrollado

El sistema cubre el corpus completo de actas del Pleno publicadas por el Ayuntamiento de Bilbao entre 2007 y 2026 (3.422 proposiciones), con extracción de metadatos, clasificación temática, dos sistemas de recuperación de información independientes y una interfaz web conversacional común a ambos.

Quedan fuera del alcance de esta entrega:

- El enlazado del grafo de conocimiento con Wikidata para desambiguar y enriquecer entidades no personales (empresas, lugares, organismos). Se valoró como extensión natural del grafo RDF/OWL, pero se descartó para esta entrega por el coste de desambiguación fiable que exige –en particular, distinguir entidades homónimas sin introducir enlaces incorrectos– y queda recogido como trabajo futuro (Capítulo 9).
- La desambiguación por género de concejales homónimos en la capa de voto nominal, más allá de la resolución por apellido ya implementada (Capítulo 7).
- Una evaluación con usuarios reales del sistema: la evaluación de este trabajo es exclusivamente técnica, sobre una batería de preguntas de referencia verificada contra las actas originales (Capítulo 8), sin sesiones de uso con los perfiles reales identificados en la Sección 1.1.1.

1.3. Conexión con los Objetivos de Desarrollo Sostenible

Con el objetivo de conseguir un futuro sostenible en el que se haya erradicado la desigualdad, se proteja el medioambiente y se garantice el bienestar de todos, los estados miembros de las Naciones Unidas aprobaron 17 objetivos el 25 de septiembre de 2015, con el propósito de cumplirlos para el año 2030.

El Objetivo de Desarrollo Sostenible (ODS) 16, *Paz, justicia e instituciones sólidas*, busca promover sociedades pacíficas e inclusivas, facilitar el acceso a la justicia para todos y construir instituciones eficaces, responsables e inclusivas a todos los niveles. En particular, su meta 16.10 persigue garantizar el acceso público a la información y proteger las libertades fundamentales, de acuerdo con la legislación nacional y los acuerdos internacionales.

El presente TFG se alinea con este objetivo al desarrollar una herramienta que convierte un archivo público municipal –las actas del Pleno del Ayuntamiento de Bilbao– en una fuente consultable en lenguaje natural, con cifras y citas verificables a la fuente original. Aunque las actas ya son públicas, su volumen (cerca de veinte años, más de un centenar de páginas por sesión) y su formato PDF no estructurado las hacen, en la práctica, de difícil acceso para quien no dispone del tiempo o la pericia necesarios para revisarlas manualmente. El sistema desarrollado reduce esa asimetría de información y facilita el escrutinio de la actividad municipal por parte de la ciudadanía, la prensa y la investigación, tal como se detalla en la Sección 1.1.1.

En segundo término, el trabajo conecta también con el ODS 11, *Ciudades y comunidades sostenibles*, cuya meta 11.3 promueve una urbanización inclusiva y participativa. Un acceso más directo al historial de decisiones del Pleno –qué se propuso, quién lo propuso y qué se decidió– es una condición previa para que la ciudadanía pueda participar de forma informada en los asuntos municipales, más allá del mero acceso a la información que cubre el ODS 16.



Figura 1: Icono del Objetivo 16: Paz, justicia e instituciones sólidas



Figura 2: Icono del Objetivo 11: Ciudades y comunidades sostenibles

1.4. Estructura de la memoria

Esta memoria se organiza como sigue. El Capítulo 2 introduce los conceptos técnicos en los que se apoya el sistema (modelos de lenguaje, RAG, grafos de conocimiento y GraphRAG) y describe el entorno institucional del Pleno del Ayuntamiento de Bilbao. El Capítulo 3 recoge los requisitos del sistema y el estado del arte de las tecnologías empleadas. El Capítulo 4 recoge la planificación temporal seguida, la evaluación económica y el análisis de riesgos del proyecto. El Capítulo 5 analiza las principales alternativas tecnológicas evaluadas antes de fijar la arquitectura final. El Capítulo 6 describe en detalle la solución desarrollada: los dos sistemas de recuperación de información contruidos –uno basado en búsqueda vectorial y otro en un grafo de conocimiento RDF/OWL consultado por SPARQL– y la interfaz web conversacional que los expone al usuario. El Capítulo 7 describe el corpus de actas de partida y el pipeline que lo transforma en proposiciones estructuradas. El Capítulo 8 presenta la evaluación comparativa de ambos sistemas. La memoria cierra con las conclusiones y los anexos.

2. Contexto

En este capítulo se presenta el contexto en el que se enmarca el trabajo, se introducen los conceptos de LLM, RAG, grafos de conocimiento y GraphRAG, que constituyen la base técnica del sistema desarrollado, y se describe el entorno institucional –el Pleno del Ayuntamiento de Bilbao– sobre el que se aplica.

2.1. Transparencia y digitalización de la administración pública

La transparencia y el acceso a la información pública son, desde hace más de una década, un objetivo explícito de la administración española. La Ley 19/2013, de 9 de diciembre, de transparencia, acceso a la información pública y buen gobierno [1], obliga a las administraciones públicas a publicar de forma activa la información relativa a su actividad institucional. En paralelo, el movimiento de *open government* promueve que esa información no solo se publique, sino que se haga accesible y reutilizable, en vez de limitarse a cumplir el mínimo legal de publicación.

En la práctica, sin embargo, publicar un documento no equivale a hacerlo accesible. Los portales de transparencia municipales publican de forma sistemática actas, órdenes del día y resúmenes de sesión en formato PDF, un formato pensado para la lectura secuencial y no para la consulta puntual ni el análisis agregado. Cuando el volumen de documentos publicados crece –como ocurre con casi veinte años de actas del Pleno de una ciudad como Bilbao– esa distancia entre “publicado” y “accesible” se hace más evidente: la información está disponible en sentido legal, pero encontrar un dato concreto dentro de ella exige un esfuerzo de búsqueda manual que en la práctica limita quién puede efectivamente usarla.

En este contexto, las técnicas de inteligencia artificial que permiten consultar documentación extensa en lenguaje natural –y en particular las técnicas RAG y GraphRAG que se presentan en las siguientes secciones– ofrecen una vía para cerrar esa distancia entre publicación y acceso real, aplicada aquí a un caso concreto de documentación administrativa pública.

2.2. El auge de los LLMs

Los modelos de lenguaje de gran tamaño, conocidos como LLM por sus siglas en inglés *Large Language Models*, son modelos de inteligencia artificial entrenados sobre corpus masivos de texto que, dada una secuencia de entrada, predicen la continuación más probable. Esta capacidad, combinada con un ajuste posterior para seguir instrucciones, les permite realizar tareas tan diversas como responder preguntas, resumir documentos o

mantener una conversación con el usuario a partir de una instrucción (*prompt*).

El interés generalizado por los LLM se intensificó a partir de noviembre de 2022, cuando OpenAI presentó ChatGPT [4], una interfaz conversacional que popularizó el uso de estos modelos entre el público general. Desde entonces, la oferta de LLM disponibles –tanto propietarios como de código abierto– se ha ampliado considerablemente, lo que permite hoy elegir entre modelos servidos como API en la nube o modelos más pequeños ejecutables en local.

Un LLM, sin embargo, no tiene por sí mismo acceso a información posterior a su entrenamiento ni a documentos privados o muy específicos –como las actas de un ayuntamiento concreto–, y tampoco garantiza que lo que genera sea correcto: puede producir afirmaciones plausibles pero falsas, fenómeno conocido como *alucinación* [5], especialmente relevante en un contexto donde se maneja información institucional que debe ser verificable. A diferencia de un escenario con documentación empresarial confidencial, en este trabajo las actas del Pleno son de por sí públicas, por lo que la motivación para complementar el LLM con una fuente documental externa no es la confidencialidad, sino la precisión y la trazabilidad de cada dato: la respuesta debe poder verificarse contra el documento original, algo que el conocimiento interno del modelo no puede ofrecer por sí solo. Ambas limitaciones –la falta de acceso a documentación específica y la falta de verificabilidad– son las que motivan la técnica que se presenta a continuación.

2.3. RAG

La generación aumentada por recuperación, conocida como RAG por sus siglas en inglés *Retrieval-Augmented Generation* [2], es una técnica que combina un LLM con un mecanismo de recuperación de información, con el objetivo de que el modelo genere respuestas apoyándose en información obtenida de una base de conocimiento externa en lugar de únicamente en lo aprendido durante su entrenamiento.

El funcionamiento de un sistema RAG puede dividirse en dos fases. En la fase de preparación se construye la base de conocimiento: los documentos se procesan y se dividen en fragmentos más pequeños (*chunks*), que se transforman en representaciones vectoriales (*embeddings*) –números que capturan el significado del texto, de forma que fragmentos semánticamente similares quedan cerca en el espacio vectorial– y se almacenan en una base de datos vectorial. En la fase de consulta, la pregunta del usuario se transforma también en un *embedding*, se compara con los almacenados para recuperar los fragmentos más relevantes, y estos se incorporan al *prompt* que recibe el LLM para generar la respuesta.

Esta arquitectura tiene dos ventajas directas para este proyecto: permite responder sobre un corpus privado y actualizable (las actas del Pleno) sin reentrenar ningún modelo, y permite citar la fuente exacta de cada afirmación, ya que se conoce qué fragmentos –y por tanto qué documento y página– sustentan la respuesta generada.

La variante más directa de RAG se conoce como *Naive RAG*, que sigue exactamente el esquema de dos fases descrito arriba sin ningún refinamiento adicional. Sobre esa base existen variantes más avanzadas [10]: *Advanced RAG* introduce mejoras en las distintas fases del proceso –como la reformulación de la consulta o la reordenación de los fragmentos recuperados– sin cambiar la arquitectura de fondo; y otras aproximaciones sustituyen el almacén de fragmentos de texto por una base de conocimiento estructurada, como un grafo de conocimiento, dando lugar a GraphRAG [3] (véanse las Secciones 2.4 y 2.5).

En este trabajo se implementan dos sistemas de recuperación sobre el mismo corpus, no uno solo: un RAG vectorial de tipo *Advanced RAG* –con recuperación híbrida y reordenación de resultados– y un sistema GraphRAG completo, con el fin de comparar ambos enfoques sobre las mismas preguntas (Capítulo 8).

2.4. Grafos de Conocimiento

Un grafo de conocimiento representa la información como una red de entidades (nodos) y relaciones entre ellas (aristas), en lugar de como texto libre [6]. El estándar utilizado en este trabajo es RDF (*Resource Description Framework*) [7], que modela cada hecho como una tripleta *sujeto-predicado-objeto* (por ejemplo, **proposición X** --presentadaPor-->Grupo PP). Sobre RDF se puede definir una ontología con OWL (*Web Ontology Language*) [8] –las clases y relaciones válidas del dominio– y consultar el grafo con el lenguaje SPARQL [9].

Una ventaja de este modelo frente al texto libre es el razonamiento automático: un motor de inferencia (*reasoner*) puede derivar hechos nuevos que no están escritos explícitamente pero se siguen de la ontología –por ejemplo, que una proposición sobre “desahucios” trata también, por herencia temática, de “vivienda”– sin que haga falta repetir esa relación en cada dato.

2.5. GraphRAG

GraphRAG es la variante de RAG en la que la fuente de recuperación no es un almacén de fragmentos de texto sino un grafo de conocimiento consultado mediante un lenguaje de consulta estructurado (SPARQL en este trabajo). En lugar de recuperar pasajes de texto parecidos a la pregunta, un LLM traduce la pregunta en lenguaje natural a una consulta formal, el motor de grafos la ejecuta y devuelve filas de datos exactos, que un segundo LLM convierte en una respuesta narrada.

Esto resulta especialmente adecuado para preguntas de agregación y razonamiento multi-salto –“¿qué grupo ha presentado más proposiciones sobre vivienda?”, “¿cuántas se han aprobado por año?”– que un sistema de recuperación de texto libre no puede responder con precisión, porque exigen contar y cruzar datos de todo el corpus, no solo encontrar un pasaje parecido a la pregunta. Es, junto con el RAG vectorial tradicional, uno de los dos sistemas comparados en este TFG.

2.6. El Pleno del Ayuntamiento de Bilbao

Este trabajo se ha desarrollado sobre la documentación pública del Pleno del Ayuntamiento de Bilbao, el órgano superior de gobierno y control del municipio, integrado por la alcaldía y los concejales electos en cada mandato. En sus sesiones, ordinarias o extraordinarias, los distintos grupos políticos y la propia alcaldía presentan proposiciones que se debaten y se someten a votación; el resultado de esa votación –aprobada, rechazada, aprobada con enmienda o decaída– queda recogido, junto con el resto del debate, en el acta de la sesión.

El Ayuntamiento publica estas actas, junto con el resto de documentación de cada



Figura 3: Fachada del Ayuntamiento de Bilbao
Fuente: Wikimedia Commons, licencia CC0 (dominio público).

sesión (orden del día, extractos, resumen), en su portal de actas del Pleno, de acceso público. Es precisamente este archivo –de casi veinte años y 3.422 proposiciones– el que constituye el corpus documental de este trabajo; su descripción detallada, junto con el proceso que lo transforma en datos estructurados, se recoge en el Capítulo 7.

3. Descripción de requerimientos y análisis del estado del arte

El corpus documental de partida –las actas del Pleno– se describe en detalle, junto con su preprocesado, en el Capítulo 7.

3.1. Requisitos del sistema

A partir de los objetivos específicos fijados en la Sección 1.2.1 se derivan los requisitos funcionales y no funcionales que debe cumplir el sistema.

3.1.1. Requisitos funcionales

ID	Descripción
RF1	Extraer de forma automatizada las proposiciones individuales de cada acta en PDF, junto con fecha, grupo o particular proponente, tema, entidades mencionadas, resultado de la votación y página de origen.
RF2	Construir un grafo de conocimiento RDF/OWL que modele proposiciones, grupos políticos, concejales y temas, con razonamiento automático sobre relaciones temáticas jerárquicas (<i>roll-up</i> vía SKOS).
RF3	Derivar el resultado de la votación y el voto nominal por concejal mediante una capa determinista basada en el texto literal del acta, que prevalezca sobre la clasificación del LLM cuando el acta permite verificarla.
RF4	Implementar un sistema de RAG vectorial con recuperación híbrida (semántica, literal y temática) y reordenación de resultados.
RF5	Implementar un sistema GraphRAG que traduzca la pregunta del usuario a una consulta SPARQL, la ejecute sobre el grafo y narre la respuesta a partir de los datos obtenidos.
RF6	Citar, para cada dato mostrado por cualquiera de los dos sistemas, el documento y la página exacta del PDF de origen.
RF7	Exponer ambos sistemas mediante una interfaz web conversacional común.
RF8	Validar la integridad estructural del grafo de conocimiento mediante restricciones SHACL, de forma independiente del código que lo construye.
RF9	Evaluar de forma comparativa ambos sistemas sobre un conjunto de preguntas de referencia con respuesta verificada a mano contra las actas originales.

Tabla 1: Requisitos funcionales del sistema

3.1.2. Requisitos no funcionales

ID	Descripción
RNF1	Trazabilidad. Toda respuesta debe poder contrastarse contra el documento original; no es aceptable una respuesta sin fuente citable.
RNF2	Precisión sobre cobertura. Ante una pregunta que el sistema no pueda responder con datos verificables, se prefiere que lo indique explícitamente antes que generar una respuesta plausible pero no respaldada por el corpus.
RNF3	Coste. El sistema debe poder operar con modelos de lenguaje locales (Ollama) o con niveles gratuitos de API en la nube, sin depender de un presupuesto de inferencia elevado.
RNF4	Idioma. Las consultas y respuestas se producen en castellano, aunque el corpus contiene fragmentos en euskera.
RNF5	Mantenibilidad. La capa determinista y la capa basada en LLM deben mantenerse separadas, de forma que un error sistemático de clasificación pueda corregirse sin reenriquecer ni reentrenar.

Tabla 2: Requisitos no funcionales del sistema

3.2. Estado del arte de las tecnologías utilizadas

Además de los conceptos generales de LLM, RAG y GraphRAG presentados en el Capítulo 2, este trabajo se apoya en dos líneas de investigación más específicas: la mejora de la recuperación en sistemas RAG mediante reordenación de resultados, y la fiabilidad de la generación de consultas formales (SPARQL o SQL) a partir de lenguaje natural con LLM –el componente más crítico del sistema GraphRAG, porque un error aquí produce una cifra incorrecta narrada como si fuera un hecho verificado, en vez de un fallo visible.

3.2.1. Recuperación híbrida y reordenación de resultados

La combinación de varios canales de recuperación (semántico, léxico y, en este caso, temático) con una reordenación posterior de los resultados es una de las mejoras características de lo que la literatura denomina *Advanced RAG* frente al esquema *Naive RAG* [10]. La reordenación mediante un modelo *cross-encoder* –que evalúa conjuntamente la pregunta y cada fragmento candidato, en vez de compararlos por separado como hace la búsqueda por *embeddings*– fue propuesta originalmente para recuperación de pasajes con BERT [11] y hoy es una técnica estándar para mejorar la precisión de los primeros resultados devueltos por un motor de recuperación semántica. En este trabajo se aplica mediante el servicio de reordenación de Cohere sobre los candidatos de los tres canales de búsqueda (Capítulo 6).

3.2.2. Fiabilidad de la generación de SPARQL con LLM

La traducción de lenguaje natural a consultas formales mediante LLM es un área de investigación activa, tanto para SPARQL sobre grafos de conocimiento como para SQL sobre bases de datos relacionales –problema estructuralmente equivalente al que resuelve el sistema GraphRAG de este trabajo. La literatura reciente converge en varios hallazgos

que han condicionado directamente las decisiones de diseño de este sistema (desarrolladas con más detalle en los Capítulos 5 y 6):

- **El *zero-shot* puro es insuficiente.** Sin ejemplos de referencia en el *prompt*, un LLM genera consultas SPARQL sintácticamente válidas mucho más a menudo que semánticamente correctas; incluir ejemplos (*few-shot*) mejora sustancialmente la tasa de acierto [12].
- **La selección de ejemplos por similitud no es automáticamente superior a alternativas más simples.** Un estudio sobre un grafo de conocimiento de accidentes de aviación encontró que un *prompt* simple con ejemplos aleatorios podía igualar a estrategias de selección por similitud semántica [13], mientras que otros trabajos en *text-to-SQL* sí encuentran ventaja consistente en la selección dinámica por *embedding* sobre ejemplos fijos [14]; la ganancia depende en buena medida de la capacidad del modelo base para aprovechar esa selección.
- **El tamaño del modelo tiene rendimientos decrecientes.** En comparativas cruzadas de familias de modelos sobre generación de consultas, la técnica de *prompting* importa tanto o más que el número de parámetros [15], y modelos pequeños bien afinados a la tarea pueden superar a modelos varias veces mayores sin ese afinamiento [16].
- **Los sistemas basados en plantillas fijas siguen siendo una alternativa con precedente** para preguntas dentro de un catálogo conocido, a cambio de perder flexibilidad ante formulaciones no previstas –el compromiso clásico entre cobertura y fiabilidad [17].

Estos hallazgos –en particular, la insuficiencia del *zero-shot*, la utilidad limitada de la selección por similitud según el modelo, y los rendimientos decrecientes del tamaño del modelo– se contrastan con resultados propios obtenidos sobre el grafo de este proyecto en el Capítulo 5, y motivan directamente la capa determinista de corrección de consultas SPARQL descrita en el Capítulo 6.

4. Planificación del proyecto

4.1. Diagrama EDT

La Figura 4 muestra la Estructura de Desglose del Trabajo (EDT) del proyecto, con los cinco paquetes de trabajo de primer nivel y sus subpaquetes, que se detallan en la Sección 4.2.




Figura 4: Diagrama EDT del proyecto

4.2. Descripción de tareas

En esta sección se describen los paquetes de trabajo mostrados en el diagrama EDT. Cada paquete se presenta en una tabla con su tiempo estimado, descripción, recursos empleados, predecesores y entregables –mismo formato en toda la memoria, un color por categoría de primer nivel del EDT.

1. Gestión y planificación	
Tiempo estimado	45 horas
Descripción	Tareas relacionadas con la planificación del proyecto y la gestión del tiempo con el director.
Recursos	Reuniones periódicas con el director, herramienta de diagramación.
Predecesores	-
Entregables/salidas	Diagramas EDT y Gantt, apuntes de seguimiento del trabajo.

Tabla 3: Paquete de trabajo: 1. Gestión y planificación

1.1. Reuniones con el director	
Tiempo estimado	30 horas
Descripción	Reuniones periódicas de seguimiento con el director para revisar el avance, resolver dudas técnicas y ajustar la planificación.
Recursos	Videollamada / presencial.
Predecesores	-
Entregables/salidas	Valoraciones del trabajo realizado y tareas siguientes acordadas.

Tabla 4: Paquete de trabajo: 1.1. Reuniones con el director

1.2. Gestión del tiempo	
Tiempo estimado	15 horas
Descripción	Planificación y seguimiento del tiempo dedicado a cada paquete de trabajo; elaboración de los diagramas EDT y Gantt.
Recursos	Herramienta de diagramación (Draw.io).
Predecesores	-
Entregables/salidas	Diagramas EDT y Gantt.

Tabla 5: Paquete de trabajo: 1.2. Gestión del tiempo

2. Investigación y estudio previo	
Tiempo estimado	70 horas
Descripción	Estudio de las técnicas y tecnologías en las que se apoya el sistema, y análisis de las principales alternativas tecnológicas antes de fijar la arquitectura.
Recursos	Los recursos empleados se especifican en cada subpaquete.
Predecesores	-
Entregables/salidas	Capítulos de Contexto y Análisis de alternativas de la memoria.

Tabla 6: Paquete de trabajo: 2. Investigación y estudio previo

2.1. Estudio del estado del arte	
Tiempo estimado	30 horas
Descripción	Estudio de LLM, RAG y sistemas GraphRAG existentes, y de trabajos similares sobre documentación administrativa.
Recursos	Documentación técnica y bibliografía de referencia.
Predecesores	-
Entregables/salidas	Capítulo de Contexto y estado del arte de la memoria.

Tabla 7: Paquete de trabajo: 2.1. Estudio del estado del arte

2.2. Análisis de alternativas tecnológicas	
Tiempo estimado	40 horas
Descripción	Comparación de LLM local frente a API en la nube, almacenamiento del grafo (rdflib/OWL-RL frente a una base de grafos dedicada) y estrategia de recuperación vectorial, incluyendo el diseño de la ontología OWL y el enfoque de razonamiento de GraphRAG.
Recursos	Documentación de las tecnologías evaluadas, pruebas exploratorias.
Predecesores	2.1. Estudio del estado del arte
Entregables/salidas	Capítulo de Análisis de alternativas de la memoria.

Tabla 8: Paquete de trabajo: 2.2. Análisis de alternativas tecnológicas

3. Desarrollo del sistema	
Tiempo estimado	135 horas
Descripción	Implementación del corpus estructurado, los dos sistemas de recuperación de información y la interfaz web.
Recursos	Los recursos empleados se especifican en cada subpaquete.
Predecesores	2.2. Análisis de alternativas tecnológicas
Entregables/salidas	Sistema completo: corpus estructurado, grafo de conocimiento, RAG vectorial, GraphRAG e interfaz web.

Tabla 9: Paquete de trabajo: 3. Desarrollo del sistema

3.1. Extracción y preprocesado del corpus	
Tiempo estimado	20 horas de trabajo activo
Descripción	Scraping del portal de actas, extracción de proposiciones y enriquecimiento temático mediante LLM (Capítulo 7). No incluye el tiempo de cómputo del propio enriquecimiento, que corre sin supervisión (ver Sección 4.5).
Recursos	Python, LangChain, API de Gemini.
Predecesores	2.2. Análisis de alternativas tecnológicas
Entregables/salidas	Corpus estructurado de proposiciones (<code>proposals_enriched.jsonl</code>).

Tabla 10: Paquete de trabajo: 3.1. Extracción y preprocesado del corpus

3.2. RAG vectorial	
Tiempo estimado	55 horas
Descripción	Implementación de la recuperación híbrida (semántica, literal y temática), reordenación de resultados y generación de respuestas con citación de fuentes.
Recursos	ChromaDB, LangChain, Cohere (reordenación), Groq/Ollama (generación).
Predecesores	3.1. Extracción y preprocesado del corpus
Entregables/salidas	Sistema RAG vectorial funcional.

Tabla 11: Paquete de trabajo: 3.2. RAG vectorial

3.3. GraphRAG	
Tiempo estimado	40 horas
Descripción	Construcción del grafo RDF/OWL, razonamiento automático, generación de SPARQL a partir de lenguaje natural y sanitización de los anti-patrones más frecuentes en las consultas generadas por el LLM.
Recursos	rdflib, owlrl, Ollama (generación de SPARQL y narración).
Predecesores	3.1. Extracción y preprocesado del corpus
Entregables/salidas	Sistema GraphRAG funcional (<code>bilbao_reasoned.ttl</code> + <code>graph_rag_sparql.py</code>).

Tabla 12: Paquete de trabajo: 3.3. GraphRAG

3.4. Interfaz web	
Tiempo estimado	20 horas
Descripción	Integración de ambos sistemas de recuperación en una interfaz web conversacional común, con citación de fuentes enlazada a la página exacta del PDF. Al construirse sobre Chainlit, un <i>framework</i> ya dado, el esfuerzo se centra en la integración de los dos <i>backends</i> , no en construir la interfaz desde cero.
Recursos	Chainlit.
Predecesores	3.2. RAG vectorial, 3.3. GraphRAG
Entregables/salidas	Interfaz web funcional.

Tabla 13: Paquete de trabajo: 3.4. Interfaz web

4. Evaluación del sistema	
Tiempo estimado	80 horas
Descripción	Diseño y ejecución de la evaluación comparativa de ambos sistemas, y validación de las respuestas contra las actas originales en PDF.
Recursos	Los recursos empleados se especifican en cada subpaquete.
Predecesores	3.4. Interfaz web
Entregables/salidas	Resultados de la evaluación comparativa (Capítulo 8).

Tabla 14: Paquete de trabajo: 4. Evaluación del sistema

4.1. Diseño de la batería de preguntas de referencia	
Tiempo estimado	15 horas
Descripción	Diseño de las preguntas de referencia y verificación manual de su respuesta correcta contra las actas originales.
Recursos	Lectura directa de las actas en PDF.
Predecesores	3.4. Interfaz web
Entregables/salidas	Batería de preguntas de referencia con respuesta verificada.

Tabla 15: Paquete de trabajo: 4.1. Diseño de la batería de preguntas de referencia

4.2. Evaluaciones y comparativa	
Tiempo estimado	40 horas
Descripción	Ejecución de la batería sobre ambos sistemas, análisis de la calidad de recuperación y de generación, y comparativa GraphRAG frente a RAG vectorial.
Recursos	Scripts de evaluación propios.
Predecesores	4.1. Diseño de la batería de preguntas de referencia
Entregables/salidas	Resultados comparativos entre ambos sistemas.

Tabla 16: Paquete de trabajo: 4.2. Evaluaciones y comparativa

4.3. Validación contra PDF real y regresión	
Tiempo estimado	25 horas
Descripción	Verificación manual del contenido de las respuestas contra el texto original de las actas (no solo contra la estructura de la respuesta), y ejecución de la suite de regresión ante cada cambio relevante.
Recursos	scripts/regression_qa.py, lectura directa de PDF.
Predecesores	4.2. Evaluaciones y comparativa
Entregables/salidas	Conjunto de casos verificados y corregidos (véase decisiones_tecnicas.md para el detalle de los casos encontrados).

Tabla 17: Paquete de trabajo: 4.3. Validación contra PDF real y regresión

4.2.1. Gestión del proyecto

4.2.2. Investigación y estudio previo

4.2.3. Desarrollo del sistema

4.2.4. Evaluación del sistema

4.2.5. Documentación

5. Documentación	
Tiempo estimado	90 horas
Descripción	Redacción de la memoria del TFG y de la documentación técnica del proyecto.
Recursos	Los recursos empleados se especifican en cada subpaquete.
Predecesores	4.3. Validación contra PDF real y regresión
Entregables/salidas	Memoria del TFG.

Tabla 18: Paquete de trabajo: 5. Documentación

5.1. Redacción de la memoria	
Tiempo estimado	70 horas
Descripción	Redacción de los capítulos de la memoria del TFG.
Recursos	L ^A T _E X (plantilla EHU).
Predecesores	4.3. Validación contra PDF real y regresión
Entregables/salidas	Memoria del TFG.

Tabla 19: Paquete de trabajo: 5.1. Redacción de la memoria

5.2. Documentación técnica	
Tiempo estimado	20 horas
Descripción	Documentación del razonamiento detrás de las decisiones técnicas no evidentes del sistema, separada del código (<code>decisiones_tecnicas.md</code>), y de los procedimientos de despliegue y uso (<i>READMEs</i> , <i>runbook</i>).
Recursos	Markdown.
Predecesores	- (paralelo al resto de paquetes)
Entregables/salidas	<code>decisiones_tecnicas.md</code> , <i>READMEs</i> y <i>runbook</i> del proyecto.

Tabla 20: Paquete de trabajo: 5.2. Documentación técnica

4.3. Gestión del tiempo

4.3.1. Estimación de horas frente a duración real

4.3.2. Diagrama de Gantt

La Figura 5 muestra la planificación temporal del proyecto, desde el inicio de los primeros trabajos (22 de enero de 2026) hasta la fecha límite de entrega de la memoria (15 de octubre de 2026), repartiendo las 420 horas estimadas de la EDT (Sección 4.2) en 38 semanas. Las tareas de gestión (1.1 y 1.2) y la documentación técnica (5.2) se desarrollan de forma continua en paralelo al resto, en vez de en un bloque cerrado.




Figura 5: Diagrama de Gantt del proyecto (semanas desde el 22 de enero de 2026)

4.4. Metodología de desarrollo

El desarrollo ha seguido un enfoque iterativo: cada componente se implementa, se prueba en vivo contra preguntas reales y se corrige antes de pasar al siguiente, en vez de implementar el sistema completo y evaluarlo solo al final. Cada iteración de corrección se apoya en dos verificaciones complementarias: una suite de regresión automática (`scripts/regression_qa.py`) que se relanza tras cualquier cambio relevante en la recuperación o la generación de SPARQL, y una validación manual contra el texto original de las actas en PDF –no solo contra la estructura de la respuesta o el propio sistema– para detectar fallos que la regresión automática no puede ver, como una mezcla de contenido entre dos proposiciones distintas dentro de un mismo bloque bien formado. Este proceso, con sus hallazgos y las correcciones aplicadas en cada ronda, queda documentado en `decisiones_tecnicas.md`, que sirve además de base directa para la Sección 6 de esta memoria.

4.5. Evaluación económica

4.5.1. Costes por mano de obra

El coste de mano de obra se calcula a partir del total de horas estimadas en el diagrama EDT (Sección 4.2), valoradas a la tarifa de un ingeniero junior. En vez de una cifra de referencia arbitraria, se toma el salario mínimo real fijado por convenio: el XIX Convenio colectivo estatal de empresas de consultoría, tecnologías de la información y estudios de mercado y de la opinión pública [18] establece una jornada anual de 1.800 horas (art. 20), y su tabla salarial actualizada para 2026 [19] fija en 29.949,83 €/año el salario de la categoría “Titulado de grado superior” –la que corresponde a un Grado universitario de 240 créditos ECTS como el de este TFG, no la categoría inferior “Titulado de grado medio” (antigua diplomatura de 3 años)–. Esto equivale a una tarifa de 16,64 €/h.

Concepto	Valor
Horas totales estimadas	420 h
Tarifa/hora (29.949,83 €/año “Titulado de grado superior” ÷ 1.800 h/año)	16,64 €/h
Coste de mano de obra	6.988,29 €

Tabla 21: Coste de mano de obra

4.5.2. Costes en hardware

El proyecto se ha desarrollado con dos equipos propios: un portátil, usado para la práctica totalidad del trabajo activo (desarrollo, redacción, reuniones), y un ordenador de sobremesa, usado únicamente para el cómputo sin supervisión que no requiere intervención activa –el enriquecimiento LLM local del corpus completo y el estudio de comparación de modelos para la generación de SPARQL (Sección 2.5)–. Ambos equipos se amortizan de forma proporcional a las horas dedicadas al proyecto sobre una vida útil estimada de 4 años (~7.000 horas de uso).

¹Precio y horas de uso estimados; especificaciones exactas pendientes de confirmar.

Equipo	Precio	Horas usadas	Vida útil	Coste
Portátil (Huawei, Ryzen 5)	650 €	420 h	7.000 h	39 €
Ordenador de sobremesa ¹	900 €	65 h	7.000 h	8 €
Coste de hardware				47 €

Tabla 22: Coste de hardware (amortizado)

4.5.3. Costes en software

Todas las herramientas de software empleadas son de código abierto o se han usado en su capa gratuita (ChromaDB, LangChain, Chainlit, Ollama, Groq y el plan de prueba de Cohere), salvo el enriquecimiento temático del corpus con la API de pago de Gemini, cuyo coste real quedó medido y documentado durante el desarrollo.

Servicio	Coste
Groq (capa gratuita)	0 €
Cohere (plan de prueba)	0 €
Ollama, ChromaDB, LangChain, Chainlit (código abierto)	0 €
API de Gemini (enriquecimiento del corpus)	7 €
Coste de software	7 €

Tabla 23: Coste de software

4.5.4. Costes indirectos

Se considera como coste indirecto el consumo eléctrico de ambos equipos durante las horas dedicadas al proyecto, a una tarifa media residencial de referencia de 0,20 €/kWh.

Equipo	Consumo	Horas	Coste
Portátil	~50 W	420 h	4 €
Ordenador de sobremesa	~300 W	65 h	4 €
Coste indirecto (electricidad)			8 €

Tabla 24: Costes indirectos (electricidad)

4.5.5. Coste total

El coste de mano de obra domina claramente el presupuesto (~99 % del total), lo cual es coherente con un proyecto que no requiere hardware especializado ni servicios de pago más allá de una única pasada puntual de enriquecimiento del corpus.

4.6. Análisis de riesgos

4.6.1. Medidas de prevención y contingencia

Concepto	Coste
Mano de obra	6.988,29 €
Hardware (amortizado)	47 €
Software	7 €
Indirectos (electricidad)	8 €
Coste total	7.050,29 €

Tabla 25: Coste total del proyecto

1. Dependencia de APIs externas (Groq)	
Descripción	El sistema usa la API de Groq para generar las respuestas finales; si el servicio falla o se agota la cuota diaria, la calidad de la respuesta puede degradarse.
Plan de prevención	Vigilar el consumo de cuota antes de lanzar baterías de pruebas extensas.
Plan de contingencia	<i>Fallback</i> automático a un modelo local vía Ollama cuando Groq no responde o se agota la cuota.
Probabilidad	Media
Impacto	Bajo (el sistema sigue funcionando, con menor calidad de redacción)

Tabla 26: Riesgo: 1. Dependencia de APIs externas

2. Errores silenciosos en la generación de SPARQL	
Descripción	El LLM puede generar una consulta SPARQL sintácticamente válida pero semánticamente incorrecta (patrón que cuenta de más, propiedad inventada, filtro perdido...); el resultado es una cifra equivocada narrada como si fuera un hecho verificado, sin ningún error visible que la delate.
Plan de prevención	Catálogo de anti-patrones detectados y sanitizados automáticamente antes de ejecutar la consulta (<i>decisiones_tecnicas.md</i> , Sección 3.1), y validación manual contra el PDF original –no solo contra la estructura de la respuesta– en cada ronda de pruebas.
Plan de contingencia	Suite de regresión automática (<i>scripts/regression_qa.py</i>) que se relanza tras cualquier cambio en la generación de SPARQL, para detectar si una corrección nueva reintroduce un fallo ya solucionado.
Probabilidad	Alta (es, de hecho, el fallo más frecuente encontrado durante el desarrollo).
Impacto	Alto: una cifra incorrecta sin error visible es el peor caso posible para un sistema cuyo requisito central es la trazabilidad (RNF1, Capítulo 3).

Tabla 27: Riesgo: 2. Errores silenciosos en la generación de SPARQL

3. Calidad variable del OCR en actas antiguas	
Descripción	Las actas más antiguas del corpus (proceden de PDF escaneados o convertidos de forma menos cuidada) presentan errores de OCR –espacios sueltos, mezcla de euskera y castellano en los mismos nombres, cortes de palabra– que dificultan la extracción de proposiciones y la identificación de concejales.
Plan de prevención	Deduplicación de nombres de concejal mediante plegado fonético de apellidos, solape de nombres de pila y un mapa explícito de alias euskera/castellano (Sección 5.2 de <code>decisiones_tecnicas.md</code>).
Plan de contingencia	Cuando la resolución automática no alcanza confianza suficiente, la entidad se deja sin resolver en vez de asignarla de forma incorrecta –se prioriza no introducir un dato falso sobre completar el 100 % de los casos.
Probabilidad	Media (concentrada en las actas más antiguas del corpus).
Impacto	Medio: afecta a la cobertura del voto nominal y a la atribución de partido de algunos concejales, no a la fiabilidad de los datos que sí se resuelven.

Tabla 28: Riesgo: 3. Calidad variable del OCR en actas antiguas

4. Plazo de entrega ajustado con un único desarrollador	
Descripción	El proyecto lo desarrolla una sola persona, con fecha límite de entrega de la memoria el 15 de octubre de 2026 (Sección 4.2); cualquier imprevisto –de salud, técnico o de disponibilidad– no tiene margen de reasignación a otro miembro del equipo.
Plan de prevención	Seguimiento semanal del avance frente al diagrama de Gantt (Figura 5), y priorización explícita de los requisitos funcionales (Tabla 1) sobre mejoras no esenciales si el margen se estrecha.
Plan de contingencia	Recorte de alcance dentro de lo ya delimitado en la Sección 1.2.1 –p. ej. reducir el tamaño de la batería de preguntas de referencia– antes que sacrificar la trazabilidad o la corrección de los datos mostrados.
Probabilidad	Media.
Impacto	Alto: sin margen de reasignación, un imprevisto afecta directamente a la fecha de entrega.

Tabla 29: Riesgo: 4. Plazo de entrega ajustado con un único desarrollador

5. Nombres y grupos ambiguos o mal atribuidos en las actas	
Descripción	Las actas identifican a los concejales por apellido suelto, y varios comparten apellido dentro del censo (p. ej. tres concejales distintos apellidados “Gil” en mandatos distintos); sin desambiguar, el voto nominal puede atribuirse a la persona equivocada. De forma similar, una palabra genérica puede confundirse con el nombre de un grupo político (“ciudadanos” en minúscula generaba falsos positivos del partido Ciudadanos antes de corregirse).
Plan de prevención	Resolución de apellido por (apellido + mandato) contra el censo de concejales de esa legislatura, en vez de por apellido suelto; comparación exacta de grupo político contra los alias canónicos del partido en vez de coincidencia de texto libre.
Plan de contingencia	Cuando varios concejales del censo comparten apellido y grupo en la misma fecha, se emite únicamente el voto agregado por grupo (bo:votoAFavorDe) y se omite el voto nominal de esa persona, en vez de asignarlo al primer candidato activo y arriesgarse a acertar el grupo pero fallar la persona.
Probabilidad	Media (concentrada en apellidos comunes con varios concejales activos en mandatos distintos).
Impacto	Medio: afecta a la atribución de voto nominal a personas concretas, no al recuento agregado por grupo, que es el dato que más preguntas de agregación utilizan.

Tabla 30: Riesgo: 5. Nombres y grupos ambiguos o mal atribuidos en las actas

5. Análisis de alternativas

5.1. Modelos de lenguaje: local (Ollama) frente a API en la nube (Groq / Gemini)

El sistema necesita LLM en dos contextos muy distintos: generación **interactiva** (una respuesta por pregunta del usuario, en tiempo real) y enriquecimiento **por lotes** (clasificar las 3.422 proposiciones del corpus una sola vez, sin supervisión). Se evaluaron tres opciones para ambos: modelos locales servidos con Ollama, la API gratuita de Groq, y la API de pago de Gemini.

5.1.1. Puntos positivos

- **Ollama (local):** sin coste por token ni límite de cuota; los datos no salen de la máquina, relevante al tratarse de un corpus público pero cuyo procesamiento no depende de un tercero.
- **Groq:** nivel gratuito con inferencia muy rápida (`gpt-oss-120b` sirve respuestas interactivas sin necesidad de GPU propia); se usa como primera opción para la generación interactiva del RAG vectorial, con caída automática a Ollama local si falla (Sección 2.1 de `decisiones_tecnicas.md`).
- **Gemini:** coste bajo y predecible con el modelo `gemini-3.5-flash-lite` (0,30 \$/1,50 \$ por millón de tokens entrada/salida); el enriquecimiento completo del corpus (~3.400 proposiciones) costó ~5 € medidos en producción.

5.1.2. Puntos negativos

- **Ollama (local):** sin GPU dedicada, la generación es inviable para procesos por lotes: ~200 s por proposición en un portátil de 6 GB de RAM habría supuesto más de 180 horas para el corpus completo. Requiere un equipo con GPU reservado para esa tarea (Sección 4.5).
- **Groq:** el nivel gratuito limita a ~100-200k tokens/día, cuota asociada a la clave de API –no se evita usando otra máquina–, insuficiente para enriquecer el corpus completo de una sola vez.
- **Gemini:** de pago desde el primer token; requiere control activo del gasto (`--max-eur` en `build_graph.py`) y los modelos disponibles para una misma clave de API cambian con el tiempo (`gemini-2.5-flash` y `2.5-flash-lite` dejaron de estar disponibles durante el desarrollo).

5.1.3. Conclusión

No se elige una única opción, sino una combinación según el contexto de uso: **Groq** para la generación interactiva (rápida y gratuita, con Ollama local como respaldo ante fallos de cuota), y **Gemini Flash-Lite** para el enriquecimiento por lotes del corpus completo (coste bajo y predecible, evita las ~180 horas que habría requerido Ollama sin GPU). Ollama local con GPU se reserva para el estudio comparativo de modelos de generación de SPARQL (Sección 3.2.2), donde repetir el mismo experimento decenas de veces sobre el mismo modelo hace prohibitivo cualquier coste por token.

5.2. Almacenamiento del grafo: rdflib/OWL-RL frente a una base de grafos dedicada (p.ej. GraphDB, Neo4j)

El grafo de conocimiento (~181.500 triples tras el razonamiento OWL-RL) puede almacenarse y consultarse con una librería en memoria (rdflib + owlrl) o con un motor de grafos dedicado desplegado como servicio (GraphDB, Neo4j, Blazegraph...).

5.2.1. Puntos positivos

- **rdflib/OWL-RL:** no requiere levantar ni mantener un servicio aparte –el grafo es un archivo (`bilbao_reasoned.ttl`) que se carga en memoria al arrancar–, lo que simplifica el despliegue y es coherente con el requisito de coste bajo (RNF3, Capítulo 3). El razonamiento OWL-RL se ejecuta una vez, de forma *offline*, al construir el grafo, no en cada consulta.
- **Base de grafos dedicada:** índices optimizados para consultas SPARQL sobre grafos de gran tamaño, soporte nativo de concurrencia entre usuarios, y herramientas de administración e inspección visual del grafo.

5.2.2. Puntos negativos

- **rdflib/OWL-RL:** el grafo completo se carga en memoria en cada arranque del proceso, y las consultas SPARQL complejas sobre grafos grandes son más lentas que con un motor dedicado con índices persistentes –a este volumen de triples, sin impacto perceptible en la interfaz conversacional, pero es una limitación que no escala indefinidamente.
- **Base de grafos dedicada:** añade una pieza de infraestructura más que instalar, configurar y mantener –y, en las opciones no libres, un coste de licencia o de alojamiento– para un proyecto de un único desarrollador y un grafo que cabe cómodamente en memoria.

5.2.3. Conclusión

Se descarta una base de grafos dedicada para esta entrega: el volumen del grafo (~181.500 triples) no lo justifica, y rdflib/OWL-RL cumple el requisito de trazabilidad y razonamiento automático (RF2, RF8) sin coste de infraestructura adicional. Si el corpus creciera en varios órdenes de magnitud, o si el sistema tuviera que atender consultas concurrentes de múltiples usuarios con baja latencia, un motor de grafos dedicado pasaría a ser la opción preferible.

5.3. Almacén vectorial y recuperación: ChromaDB e híbrida (semántica + literal + temática) frente a solo semántica

El RAG vectorial puede limitarse a la búsqueda semántica clásica por *embeddings*, o combinarla con canales adicionales de recuperación sobre el mismo almacén (ChromaDB).

5.3.1. Puntos positivos

- **Solo semántica:** arquitectura más simple, un único canal de recuperación y sin lógica adicional de fusión de resultados.
- **Híbrida (semántica + literal + temática):** cada canal cubre un fallo distinto de los otros dos. El canal literal recupera menciones únicas de nombres propios que el *embedding* no acerca lo suficiente (p. ej. una empresa citada una sola vez); el canal temático recupera fragmentos relevantes para preguntas generales sobre un tema amplio (“qué se ha hecho en movilidad”) que no comparten vocabulario textual con los fragmentos relevantes, porque mide coincidencia de *clasificación* en vez de coincidencia de *texto* (Sección 1.1 de `decisiones_tecnicas.md`).

5.3.2. Puntos negativos

- **Solo semántica:** pierde precisión exactamente en los dos casos que motivan los canales adicionales –menciones únicas y preguntas temáticas amplias–, con el riesgo de devolver “no hay información” cuando sí la hay en el corpus.
- **Híbrida:** más candidatos que fusionar y reordenar por pregunta (hasta tres canales, cada uno con sus propios candidatos), lo que exige una etapa de reordenación (Cohere) para que el volumen adicional de candidatos no degrade la relevancia de los primeros resultados, y añade complejidad de implementación y de depuración frente a un único canal.

5.3.3. Conclusión

Se adopta la recuperación híbrida sobre ChromaDB: el coste de implementación adicional se compensa con una cobertura de preguntas que la búsqueda semántica sola no alcanza, y es coherente con el requisito de precisión sobre cobertura (RNF2, Tabla 2) –preferir encontrar el dato correcto, aunque exija combinar varias estrategias de búsqueda, a que el sistema responda que no dispone de información cuando sí la tiene.

6. Descripción de la solución propuesta

El proceso de obtención y preparación del corpus sobre el que opera el sistema se describe aparte, en el Capítulo 7.

6.1. Arquitectura general del sistema

6.2. Construcción del grafo de conocimiento

6.3. Sistema de recuperación de información

6.3.1. RAG vectorial

6.3.2. GraphRAG

6.4. Generación de respuestas

6.5. Interfaz web del sistema

6.6. Flujo completo del sistema

6.7. Configuración y decisiones de implementación

6.7.1. Temperatura y parámetros de los LLM

6.7.2. Gestión de cuotas y memoria

6.7.3. Construcción del *prompt* para generación

7. Corpus y preprocesado de datos

7.1. El corpus de actas del Pleno

7.2. Pipeline de preprocesado

7.2.1. Descarga automatizada de las actas

7.2.2. Extracción de proposiciones

7.2.3. Enriquecimiento con un LLM

8. Análisis de resultados

8.1. Objetivo de la evaluación

8.2. Metodología

Categoría de pregunta	GraphRAG	Vectorial
Conteo simple	6	–
Ratio / comparación de grupos	4	–
Ranking	3	–
Consulta narrativa / contexto abierto	–	13

Tabla 31: Categorías de preguntas de la batería de referencia (ejemplo)

8.3. Análisis sobre la recuperación

8.4. Análisis sobre la generación

8.5. Comparativa GraphRAG frente a RAG vectorial

8.6. Configuración final y valoración global

8.7. Limitaciones

9. Conclusiones y trabajo futuro

9.1. Conclusiones del trabajo

9.2. Cumplimiento de objetivos

9.3. Conclusiones sobre las pruebas realizadas

9.4. Contribuciones científico-técnicas

9.5. Trabajo futuro

Bibliografía

- [1] *Ley 19/2013, de 9 de diciembre, de transparencia, acceso a la información pública y buen gobierno*. Boletín Oficial del Estado, núm. 295, de 10 de diciembre de 2013 (BOE-A-2013-12887). <https://www.boe.es/buscar/act.php?id=BOE-A-2013-12887>
- [2] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., y Kiela, D. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. Advances in Neural Information Processing Systems (NeurIPS), vol. 33, pp. 9459–9474, 2020. https://proceedings.neurips.cc/paper_files/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf
- [3] Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., Truitt, S., y Larson, J. *From Local to Global: A Graph RAG Approach to Query-Focused Summarization*. arXiv:2404.16130, 2024. <https://arxiv.org/abs/2404.16130>
- [4] OpenAI. *Introducing ChatGPT*. 30 de noviembre de 2022. <https://openai.com/index/chatgpt/>
- [5] Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., y Fung, P. *Survey of Hallucination in Natural Language Generation*. ACM Computing Surveys, vol. 55, núm. 12, art. 248, 2023. <https://doi.org/10.1145/3571730>
- [6] Hogan, A., Blomqvist, E., Cochez, M., D'Amato, C., De Melo, G., Gutierrez, C., Kirrane, S., Labra Gayo, J. E., Navigli, R., Neumaier, S., Ngonga Ngomo, A. C., Polleres, A., Rashid, S. M., Rula, A., Schmelzeisen, L., Sequeda, J., Staab, S., y Zimmermann, A. *Knowledge Graphs*. ACM Computing Surveys, vol. 54, núm. 4, art. 71, pp. 1–37, 2021. <https://doi.org/10.1145/3447772>
- [7] W3C. *RDF 1.1 Concepts and Abstract Syntax*. W3C Recommendation, 25 de febrero de 2014. <https://www.w3.org/TR/rdf11-concepts/>
- [8] Hitzler, P., Krötzsch, M., Parsia, B., Patel-Schneider, P. F., y Rudolph, S. (eds.) *OWL 2 Web Ontology Language Primer (Second Edition)*. W3C Recommendation, 11 de diciembre de 2012. <https://www.w3.org/TR/owl2-primer/>
- [9] W3C. *SPARQL 1.1 Query Language*. W3C Recommendation, 21 de marzo de 2013. <https://www.w3.org/TR/sparql11-query/>
- [10] Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., y Wang, H. *Retrieval-Augmented Generation for Large Language Models: A Survey*. arXiv:2312.10997, 2023. <https://arxiv.org/abs/2312.10997>
- [11] Nogueira, R., y Cho, K. *Passage Re-ranking with BERT*. arXiv:1901.04085, 2019. <https://arxiv.org/abs/1901.04085>

- [12] Giuliani, A., Manca, M. M., Piano, L., et al. *Are LLMs Adequate SPARQL Query Generators? Investigating Zero-Shot NL-to-SPARQL Translation*. Neural Computing and Applications, vol. 38, art. 33, 2026. <https://link.springer.com/article/10.1007/s00521-025-11799-x>
- [13] Hernandez-Camero, I. V., Garcia-Lopez, E., Garcia-Cabot, A., y Caro-Alvaro, S. *Context-Aware Few-Shot Learning SPARQL Query Generation from Natural Language on an Aviation Knowledge Graph*. Machine Learning and Knowledge Extraction, vol. 7, núm. 2, art. 52, 2025. <https://doi.org/10.3390/make7020052>
- [14] Pourhabib, A. *Robust Active Learning for Few-Shot Example Selection in Text-to-SQL*. arXiv:2606.10125, 2026. <https://arxiv.org/abs/2606.10125>
- [15] Beskorovainyi, V. *How Far Do On-Prem Open LLMs Get on Text-to-SQL? A Cross-Family Size x Technique Frontier on BIRD*. arXiv:2606.29733, 2026. <https://arxiv.org/abs/2606.29733>
- [16] Sheng, L., y Xu, S. *SLM-SQL: An Exploration of Small Language Models for Text-to-SQL*. arXiv:2507.22478, 2025. <https://arxiv.org/abs/2507.22478>
- [17] Aneja, K., Srivastava, M., Das, S., y Aneja, N. *Interpretable Question Answering with Knowledge Graphs*. arXiv:2510.19181, 2025. <https://arxiv.org/abs/2510.19181>
- [18] Dirección General de Trabajo. *Resolución de 4 de abril de 2025 por la que se registra y publica el XIX Convenio colectivo estatal de empresas de consultoría, tecnologías de la información y estudios de mercado y de la opinión pública*. Boletín Oficial del Estado (BOE-A-2025-7766), 2025. https://www.boe.es/diario_boe/txt.php?id=BOE-A-2025-7766
- [19] Dirección General de Trabajo. *Resolución de 13 de abril de 2026 por la que se registra y publica el Acta de la Comisión paritaria por la que se aprueba la actualización de las tablas salariales del XIX Convenio colectivo estatal de empresas de consultoría, tecnologías de la información y estudios de mercado y de la opinión pública*. Boletín Oficial del Estado (BOE-A-2026-9024), 2026. https://www.boe.es/diario_boe/txt.php?id=BOE-A-2026-9024